

ANDRÉ VICTOR XAVIER PIRES

PREDIÇÃO DE MARGEM DE CONFORMIDADE ELETROMAGNÉTICA EM PLACAS DE
CIRCUITO IMPRESSO MULTICAMADAS POR MODELO SUBSTITUTO INFORMADO
POR FÍSICA

(versão pré-defesa, compilada em 22 de setembro de 2026)

Plano de trabalho apresentado à comissão de Trabalho de Conclusão de Curso do curso de Engenharia Elétrica, ênfase em sistemas eletrônicos embarcados (curso noturno), Setor de Tecnologia da Universidade Federal do Paraná, como requisito para matrícula na disciplina de Trabalho de Conclusão de Curso I, conforme o Anexo I da regulamentação do curso.

Área de concentração: *Engenharia Elétrica*.

Orientador: Prof. Dr. Leandro dos Santos Coelho.

CURITIBA

2026

IDENTIFICAÇÃO

Estudante	André Victor Xavier Pires, matrícula GRR20212735
Curso	Engenharia Elétrica, ênfase em sistemas eletrônicos embarcados (curso noturno), Setor de Tecnologia, UFPR
Equipe	Trabalho individual
Disciplinas	TCC I (2026/2) e TCC II (2027/1)
Orientador	Prof. Dr. Leandro dos Santos Coelho, Departamento de Engenharia Elétrica e PPGEE, UFPR

A descrição do projeto reproduz, na ordem, os itens do Anexo I: o item 1 (título) consta da folha de rosto, os itens 2 a 9 são as seções do Capítulo 1 e o item 10 corresponde a REFERÊNCIAS. O sumário abaixo é, portanto, o próprio quadro de conferência do Anexo I.

SUMÁRIO

1	DESCRIÇÃO DO PROJETO.	3
1.1	INTRODUÇÃO	3
1.2	OBJETIVOS	4
1.2.1	Objetivo geral	4
1.2.2	Objetivos específicos	4
1.3	PÚBLICO ALVO	4
1.4	METODOLOGIA DE DESENVOLVIMENTO	5
1.4.1	Base de dados	5
1.4.2	Modelo informado por física	6
1.4.3	Camada normativa de estimativa de margem	6
1.4.4	Otimização, interpretabilidade e validação	7
1.5	RECURSOS NECESSÁRIOS	7
1.6	RESULTADOS FUNDAMENTAIS A SEREM ATINGIDOS.	7
1.7	CONTRIBUIÇÃO ESPERADA PARA A ÊNFASE E IMPORTÂNCIA PARA A FORMAÇÃO DO AUTOR	8
1.8	CRONOGRAMA	8
	REFERÊNCIAS	10

1 DESCRIÇÃO DO PROJETO

1.1 INTRODUÇÃO

Interfaces digitais atuais, como PCI Express Gen 6, DDR5 e Ethernet de 112 Gb/s, impõem tempos de transição de dezenas de picossegundos, o que leva conteúdo espectral relevante para dezenas de gigahertz. Nesse regime, trilhas comportam-se como linhas de transmissão, pares de planos como cavidades ressonantes e descontinuidades geométricas como antenas não intencionais (Johnson e Graham, 1993; Ott, 2009). A rede de distribuição de energia (*power delivery network*, PDN) ocupa posição central: os modos próprios da cavidade formada pelos planos produzem picos na curva de impedância $Z(f)$, que amplificam o ruído de comutação e o convertem em emissão irradiada pelas bordas da placa e pelos cabos a ela conectados (Bogatin, 2010).

O projetista, porém, não formula sua pergunta em termos de impedância, e sim de forma normativa: este empilhamento tem margem contra a curva-limite de emissão da norma que o produto precisa atender, no ambiente em que será usado? Hoje a resposta chega apenas ao fim do ciclo de desenvolvimento, por ensaio em laboratório acreditado sobre protótipo. A reprovação nesse ponto implica reprojeção, nova fabricação e novo agendamento de ensaio, com impacto medido em meses. Antecipar essa resposta exige avaliar milhares de configurações, e é aí que o custo computacional se torna alto demais: solvers de onda completa consomem de dezenas de minutos a horas por configuração, e mesmo métodos baseados em física, uma a duas ordens de grandeza mais rápidos (Schierholz et al., 2021; Hillebrecht et al., 2024), seguem incompatíveis com otimização automatizada.

Modelos substitutos deslocam esse custo para uma fase de treinamento única e entregam previsões em milissegundos (Swaminathan et al., 2020; Jiang et al., 2020; Zhang et al., 2021). Persiste, contudo, uma limitação estrutural: modelos orientados apenas a dados reduzem o erro numérico sem garantir consistência física, e redes treinadas sobre parâmetros de espalhamento produzem com frequência respostas não passivas ou não causais, inúteis para simulação no domínio do tempo (Torun et al., 2020). O problema se agrava quanto menor a quantidade de dados disponível, pois a rede não tem evidência suficiente para inferir, apenas deles, comportamentos que a física já descreve em forma fechada (Raissi et al., 2019).

Propõe-se, por isso, uma arquitetura de duas camadas. A primeira é um modelo substituto informado por física, que prediz $Z(f)$ a partir dos parâmetros do empilhamento, com restrições eletromagnéticas incorporadas à função de perda. A segunda é uma camada normativa determinística, que converte $Z(f)$ em uma estimativa de emissão e a compara com a curva-limite da norma e do ambiente selecionados, produzindo uma margem em decibéis. É essa margem, e não a impedância, que serve de função objetivo à otimização. Uma investigação preliminar já realizada sobre a base mostrou quais restrições podem ser usadas: o regime quase-estático segue

com precisão a lei capacitiva prevista, com inclinação logarítmica medida de $-1,018 \pm 0,008$ contra -1 teórico, enquanto o uso das frequências de ressonância como referência, inicialmente previsto como principal, foi refutado. Formula-se o problema de pesquisa:

Em que medida a incorporação de restrições eletromagnéticas conhecidas em forma fechada à função de perda de um modelo substituto neural melhora a acurácia, a consistência física e a generalização entre topologias na predição da impedância de PDNs, em função do volume de dados de treinamento, e em que medida a margem normativa dela derivada ordena empilhamentos de forma estável o suficiente para orientar decisões de projeto?

1.2 OBJETIVOS

1.2.1 Objetivo geral

Desenvolver e validar um modelo substituto informado por física que, acoplado a uma camada normativa determinística, estime a margem de conformidade eletromagnética da rede de distribuição de energia de uma placa de circuito impresso multicamadas contra as curvas-limite de emissão da norma e do ambiente de uso selecionados pelo projetista, com acurácia e latência compatíveis com a otimização do empilhamento na fase inicial de projeto.

1.2.2 Objetivos específicos

- a) implementar um pipeline incremental de extração da curva de impedância a partir dos arquivos Touchstone, validado contra propriedades analíticas conhecidas, e reunir os subconjuntos de PDN da SI/PI-Database, de 1 a 13 cavidades, em uma representação de atributos independente da topologia;
- b) verificar sobre os próprios dados quais relações analíticas da cavidade são observáveis na grandeza predita, formulando os termos de perda apenas a partir das que se confirmarem;
- c) treinar e avaliar o modelo informado por física contra um conjunto de modelos de referência, sob protocolo único, medindo a consistência física, o ganho em função do volume de treinamento e a generalização para topologias não vistas;
- d) implementar a camada normativa de estimativa de margem, medindo a estabilidade do ordenamento de empilhamentos sob variação de suas premissas, e acoplá-la a um otimizador evolutivo multiobjetivo que maximize a margem e minimize o custo de fabricação estimado;
- e) obter diretrizes de projeto interpretáveis, expressas em decibéis de margem, e publicar a implementação como software livre reproduzível.

1.3 PÚBLICO ALVO

O público primário é o engenheiro de projeto de *hardware* digital e a equipe de compatibilidade eletromagnética que o apoia, em organizações cujos produtos passam por ensaios de certificação. O momento de uso é a fase inicial de definição do empilhamento, quando número de camadas, espessura de cavidade, dielétrico e densidade de vias ainda podem ser alterados. O público secundário é a comunidade acadêmica de integridade de sinal e potência e de aprendizado informado por física, para a qual se destinam a implementação aberta, o protocolo experimental e as hipóteses formuladas de modo que possam ser refutadas. Há ainda o público institucional: o pipeline, a base reunida e a camada normativa ficam disponíveis para trabalhos futuros no Departamento de Engenharia Elétrica da UFPR.

1.4 METODOLOGIA DE DESENVOLVIMENTO

1.4.1 Base de dados

Utiliza-se a SI/PI-Database, do *Institut für Theoretische Elektrotechnik* da Universidade Técnica de Hamburgo (Schierholz et al., 2021; Hillebrecht et al., 2024), de acesso público mediante aceite dos termos de uso. A referência controlada é o subconjunto *6-Layer PCB based PDN with Two Via Arrays*, amostrado por hipercubo latino e já caracterizado por inspeção direta dos arquivos: 985 configurações, 36 portas, 334 pontos entre 1 MHz e 1 GHz e oito graus de liberdade efetivos entre os dezessete parâmetros tabulados.

O trabalho não se restringe a esse subconjunto. A base oferece catorze subconjuntos de PDN, com 1 a 13 cavidades e cerca de 135 mil configurações, todos cobrindo 1 MHz a 1 GHz e simulados pela mesma ferramenta baseada em física. Eles são combináveis porque o alvo é a autoimpedância em uma única porta, de modo que a variação no número total de portas, de 2 a 68, não altera a dimensão da saída. Exclui-se apenas o subconjunto de onda completa de 14 camadas, fora da banda e de fidelidade distinta. A união exige quatro tratamentos. O espaço de parâmetros é diferente em cada subconjunto, o que leva a adotar atributos derivados independentes da topologia, como número de cavidades, espessura total, capacitância acumulada, densidade de vias, passo normalizado e razões geométricas. A porta de interesse recebe numeração distinta em cada subconjunto, o que exige um adaptador conferido contra a folha de dados. As variantes Eurocard usam 121 pontos de frequência na mesma faixa, e são interpoladas para a grade comum. E os 119 GB comprimidos do conjunto completo excederiam o armazenamento se descompactados de uma vez, de modo que cada subconjunto é baixado, reduzido à curva de impedância e tem os arquivos brutos descartados antes do próximo. Como os desenhos de amostragem diferem, o experimento controlado de curva de aprendizado fica restrito aos subconjuntos por hipercubo latino.

O ganho não é só de volume. Com o número de cavidades variando de 1 a 13, essa grandeza passa a ser um atributo observável, o que permite testar se a capacitância efetiva

cresce com o número de cavidades em paralelo, desvio que a investigação preliminar detectou e não pôde explicar com um único subconjunto. Confirmada a relação, o termo quase-estático passa a restringir também a magnitude da resposta. A variedade de topologias permite ainda validação com topologia retida, o que torna mensurável a principal limitação de validade externa do trabalho.

1.4.2 Modelo informado por física

O alvo é a curva $y(f) = \log_{10} |Z_{11}(f)|$, obtida da matriz de espalhamento. Prediz-se a curva completa, e não um valor escalar, porque é ela que alimenta a camada normativa e porque as restrições físicas atuam sobre sua forma. A função de perda soma o erro de reconstrução, ponderado por década para compensar a subamostragem da primeira década, a três termos derivados da física: o desvio da derivada logarítmica em relação a -1 na região quase-estática, formulação que é invariante a fator multiplicativo e por isso não é afetada pelo desvio de escala observado; a monotonicidade até o nulo de série, que penaliza oscilações falsas, comuns em redes treinadas com poucos dados; e a passividade. Os pesos são hiperparâmetros críticos e serão determinados por otimização bayesiana sobre o conjunto de validação, com a sensibilidade do resultado reportada.

Os modelos de referência, avaliados sob protocolo idêntico, são regressão regularizada, floresta aleatória, *gradient boosting*, processos gaussianos e um perceptron multicamadas (Géron, 2022). Este último é o mais importante, por diferir do modelo proposto apenas pela ausência dos termos físicos, o que isola o efeito da informação física. O conjunto é particionado com semente registrada, o teste é acessado uma única vez e o ganho é medido em frações crescentes do treinamento, com significância avaliada por teste não paramétrico pareado. O critério de aceitação é $R^2 > 0,90$ sobre $|Z|_{\max}$ em teste isolado, com latência de inferência inferior a 1 ms.

1.4.3 Camada normativa de estimativa de margem

A conversão de $Z(f)$ em margem é determinística, sem aprendizado, e ocorre em três etapas com premissas declaradas. A excitação não integra a base de dados e é entrada do projetista: adota-se um modelo de corrente trapezoidal, definido por frequência de *clock*, tempo de transição e amplitude, cujo envelope espectral decai a -20 dB por década até o joelho em $1/(\pi t_r)$ e a -40 dB por década acima dele (Johnson e Graham, 1993), do que resulta $V_n(f) = |Z_{11}(f)| I(f)$. A radiação é modelada por expressões fechadas para os dois mecanismos dominantes abaixo de 1 GHz (Ott, 2009): a emissão pelas bordas do par de planos e a emissão de modo comum excitada por cabos. A comparação normativa usa as curvas-limite da CISPR 32, classes A e B (International Electrotechnical Commission, 2015), e das normas genéricas IEC 61000-6-3 (International Electrotechnical Commission, 2026) e IEC 61000-6-4 (International Electrotechnical Commission, 2018), selecionáveis pelo ambiente de uso. A margem é $m(f) = L(f) - \hat{E}(f)$ e a medida de desempenho é a menor margem na faixa.

Duas delimitações são essenciais. Os limites de emissão irradiada começam em 30 MHz, de modo que a margem é calculada sobre 30 MHz a 1 GHz. Além disso, a camada é analítica e não é calibrada contra medição, pois a base não contém dados de campo. Sua saída não é uma decisão de certificação, que depende também de gabinete, cabos, aterramento e *firmware*, e sim um indicador de triagem, válido para comparar projetos entre si. Essa validade será medida, e não suposta: varre-se um conjunto de premissas plausíveis e avalia-se a estabilidade do ordenamento pelo coeficiente de Kendall.

1.4.4 Otimização, interpretabilidade e validação

Validado o conjunto, ele é usado como função de avaliação em um problema multiobjetivo que maximiza a menor margem e minimiza um custo de fabricação estimado, por NSGA-II (Deb et al., 2002) comparado à evolução diferencial multiobjetivo (Coelho, 2010), com as soluções extremas da fronteira de Pareto conferidas por simulação de referência. A interpretabilidade emprega valores de Shapley (Lundberg e Lee, 2017) e regressão simbólica (Tessaro et al., 2026) para obter expressões algébricas que relacionem parâmetros de empilhamento à margem, com faixas de validade declaradas.

1.5 RECURSOS NECESSÁRIOS

A execução é conduzida pelo autor sob orientação do Prof. Dr. Leandro dos Santos Coelho, responsável pelas frentes de modelagem substituta, otimização e regressão simbólica. Estima-se dedicação de dez horas semanais ao longo de dois semestres letivos, com reuniões quinzenais de acompanhamento.

Não há necessidade de aquisição de equipamentos ou licenças. Basta um computador pessoal com 8 GB de memória e cerca de 60 GB livres em disco, o que é suficiente mesmo com todos os subconjuntos, dado o pré-processamento incremental. A cadeia de software é integralmente livre: numpy, pandas e scipy para manipulação numérica; scikit-rf para os arquivos Touchstone; scikit-learn e LightGBM para os modelos de referência; PyTorch para o modelo informado por física; Optuna e pymoo para otimização; SHAP e PySR para interpretabilidade; e MLflow, pytest, Hydra, Git e L^AT_EX para registro, testes, configuração, versionamento e redação. O treinamento roda em CPU, com o Google Colab gratuito como alternativa. Não há custos previstos no escopo principal. Um custo de R\$ 300 a R\$ 600 incorreria apenas na fabricação das placas de teste da validação complementar.

1.6 RESULTADOS FUNDAMENTAIS A SEREM ATINGIDOS

- a) um modelo substituto informado por física com $R^2 > 0,90$ sobre $|Z|_{\max}$ em teste isolado e latência inferior a 1 ms, e um conjunto de dados reunido a partir da base original,

reprodutível, cobrindo os subconjuntos de PDN de 1 a 13 cavidades sob representação independente da topologia;

- b) a medida do efeito da informação física sobre o erro de generalização, em função do volume de treinamento e para topologias não vistas, com significância estatística avaliada;
- c) uma camada normativa que traduz a impedância predita em margem em decibéis contra a CISPR 32 e as normas IEC 61000-6-3 e 6-4, com a estabilidade do ordenamento medida, e uma fronteira de Pareto de empilhamentos que equilibram margem e custo, com expressões analíticas interpretáveis e faixas de validade declaradas;
- d) uma implementação de código aberto, reprodutível e documentada, e, como desdobramento pretendido, um manuscrito submetido a evento da área.

1.7 CONTRIBUIÇÃO ESPERADA PARA A ÊNFASE E IMPORTÂNCIA PARA A FORMAÇÃO DO AUTOR

A ênfase em sistemas eletrônicos embarcados forma o profissional que projeta o *hardware* de um produto e responde por seu funcionamento em campo, e é nesse ponto que o trabalho atua. O sistema embarcado é onde a decisão de empilhamento, o ruído de comutação e a aprovação em ensaio deixam de ser assuntos separados: a mesma escolha de espessura de cavidade que reduz o custo da placa determina a impedância vista pelos componentes e, por consequência, a emissão medida no laboratório. A contribuição está em tratar essa camada física, em geral repassada a especialistas ou descoberta tarde por reprovação em ensaio, como objeto explícito de projeto, e em expressar seu resultado na linguagem que o projetista usa. Há também integração curricular, pois o problema exige ao mesmo tempo eletromagnetismo aplicado, teoria de circuitos e linhas de transmissão, análise de sinais no domínio da frequência, normas de compatibilidade eletromagnética e métodos numéricos.

Para a formação do autor, o trabalho desenvolve três competências. A primeira é metodológica: conduzir investigação empírica com hipóteses que podem ser refutadas e com protocolo fixado antes da observação dos resultados. A segunda é técnica: aplicar aprendizado de máquina a um problema cuja física é parcialmente conhecida em forma fechada, situação em que cabe ao engenheiro decidir o que o modelo deve aprender e o que já se sabe. A terceira é de prática profissional: distinguir o que o modelo sustenta do que não sustenta, distinção que, na camada normativa, separa um instrumento de triagem de uma afirmação de conformidade indevida.

1.8 CRONOGRAMA

O trabalho distribui-se por dois semestres letivos, conforme a Tabela 1.1. O período 2026/2 é dedicado à fundamentação e à infraestrutura de dados, e o período 2027/1 ao modelo informado por física, à camada normativa e à otimização.

Tabela 1.1 – Cronograma de execução

Atividade	TCC I (2026/2)					TCC II (2027/1)				
	ago	set	out	nov	dez	mar	abr	mai	jun	jul
Revisão bibliográfica	■	■	■							
Pipeline de extração e validação da base	■	■	■	■						
Reunião dos subconjuntos e das normas		■	■	■	■					
Modelos de referência e protocolo			■	■	■					
Entrega e apresentação de TCC I					■					
Termos físicos e calibração dos pesos						■	■	■	■	
Camada normativa e estabilidade da ordenação							■	■	■	
Otimização, interpretabilidade e validação								■	■	■
Redação			■	■	■			■	■	■
Revisão final e defesa										■

FONTE: O autor (2026).

Quatro marcos orientam a continuidade: o pipeline validado contra propriedades analíticas conhecidas, em setembro de 2026; quatro subconjuntos reunidos e o melhor modelo de referência em $R^2 > 0,80$, em novembro de 2026; o modelo informado por física superando a ablação com significância estatística, em abril de 2027; e a fronteira de Pareto conferida por simulação, em junho de 2027. O terceiro marco não condiciona a validade do trabalho, pois a hipótese pode ser refutada, e sua refutação é um resultado que também merece publicação.

REFERÊNCIAS

- Bogatin, E. (2010). *Signal and Power Integrity - Simplified*. Prentice Hall Modern Semiconductor Design Series. Prentice Hall, Upper Saddle River, 2 edition. ISBN 978-0-13-234979-6.
- Coelho, L. d. S. (2010). Gaussian quantum-behaved particle swarm optimization approaches for constrained engineering design problems. *Expert Systems with Applications*, 37(2):1676–1683.
- Deb, K. et al. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media, Sebastopol, 3 edition. ISBN 978-1-098-12597-4.
- Hillebrecht, T. et al. (2024). Generation and application of a very large dataset for signal integrity via array and link analysis. *IEEE Transactions on Electromagnetic Compatibility*, 66(6):1967–1976.
- International Electrotechnical Commission (2015). *CISPR 32: Electromagnetic compatibility of multimedia equipment - Emission requirements*. International Electrotechnical Commission, Geneva, 2.0 edition. Versão consolidada CISPR 32:2015+AMD1:2019.
- International Electrotechnical Commission (2018). *IEC 61000-6-4: Electromagnetic compatibility (EMC) - Part 6-4: Generic standards - Emission standard for industrial environments*. International Electrotechnical Commission, Geneva, 3.0 edition.
- International Electrotechnical Commission (2026). *IEC 61000-6-3: Electromagnetic compatibility (EMC) - Part 6-3: Generic standards - Emission standard for equipment in residential locations*. International Electrotechnical Commission, Geneva, 4.0 edition.
- Jiang, P., Zhou, Q. e Shao, X. (2020). *Surrogate Model-Based Engineering Design and Optimization*. Springer Tracts in Mechanical Engineering. Springer Nature Singapore, Singapore.
- Johnson, H. W. e Graham, M. (1993). *High-Speed Digital Design: A Handbook of Black Magic*. Prentice Hall, Upper Saddle River. ISBN 0-13-395724-1.
- Lundberg, S. M. e Lee, S.-I. (2017). A unified approach to interpreting model predictions. Em *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, páginas 4765–4774.
- Ott, H. W. (2009). *Electromagnetic Compatibility Engineering*. John Wiley & Sons, Hoboken. ISBN 978-0-470-18930-6.
- Raissi, M., Perdikaris, P. e Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707.
- Schierholz, M. et al. (2021). SI/PI-database of PCB-based interconnects for machine learning applications. *IEEE Access*, 9:34423–34432.
- Swaminathan, M. et al. (2020). Demystifying machine learning for signal and power integrity problems in packaging. *IEEE Transactions on Components, Packaging and Manufacturing Technology*, 10(8):1276–1295.

- Tessaro, I. et al. (2026). Robust ensemble learning framework through symbolic regression for soft sensor modeling. *Journal of Computational Science*, 98:102886.
- Torun, H. M. et al. (2020). Causal and passive parameterization of S-parameters using neural networks. *IEEE Transactions on Microwave Theory and Techniques*, 68(10):4290–4304.
- Zhang, L. et al. (2021). Fast impedance prediction for power distribution network using deep learning. *International Journal of Numerical Modelling: Electronic Networks, Devices and Fields*, 35(2):e2956.